# saemotionFruit

# Progetto di Informatica Umanistica

A.A. 2023/2024

Corso di Laurea Triennale in Informatica Alma Mater Studiorum - Università di Bologna



### 0. Introduzione

Il progetto *emotionFruit* si propone di analizzare le emozioni di canzoni in lingua inglese attraverso l'analisi del testo e l'utilizzo del semantic web. In particolare, a partire dal titolo e dall'autore di una canzone, verranno creati dei grafici che evidenziano la distribuzione di certe emozioni all'interno delle singole strofe e il loro andamento nel corso della canzone.

Lo scopo del progetto è anche quello di mettere a confronto il potere del semantic web con quello dei Large Language Models, nel nostro caso ChatGPT. Sarà quindi dedicata una sezione allo studio di una canzone del dominio confrontando nel dettaglio i grafici risultanti.

## 0.1 - Componenti del gruppo

- Elisa Casalini
- Giulia Ferrigno
- Simone Salamone
- Pietro Sami
- Alessandro Tomaiuolo

## 1. Struttura della pipeline

### 1.1 - Main

Il file main.py viene chiamato per far partire l'intera pipeline. Viene utilizzato un eseguibile rdf.sh ausiliario, che viene utilizzato per clonare la repository del machine-reader ed eseguirlo. Alla fine della pipeline vengono mostrati in output i grafici realizzati tramite la libreria matplotlib.

### 1.2 - TEXT TO CSV

Il primo passo nella pipeline è ottenere il testo della canzone e trasformare l'output per essere compatibile con l'input dello step successivo.

Il testo della canzone viene ottenuto dalla funzione getSong nel file

**lyrics\_from\_title\_lyrist.py** che utilizza una API che prende in input autore e nome della canzone e restituisce un oggetto contenente il testo assieme ad altre informazioni riguardante essa.

La funzione utilizzata per creare il CSV è **to\_csv** della libreria pandas e viene salvata in un file chiamato "out.csv".

#### 1.3 - MACHINE READER

Questo step utilizza un tool fornitoci dal professore che trasforma il CSV in un file RDF che utilizza la sintassi N-Quad. Il file in output è un file .nq che prende il nome della canzone che viene analizzata.

Per maggiori informazioni consultare il seguente link.

### 1.4 - SYNSCRAPER

Dopo aver ottenuto il file contenente bisogna estrarre solo le informazioni di nostro interesse, ovvero, i synset, in particolare vogliamo estrarre tutti i synset che compaiono come oggetto all'interno di ogni quadrupla (in parole povere, il terzo elemento di ogni tupla).

Viene scansionato il file *nome\_canzone.json*, e in base all'id della strofa viene creato il file *synScraperOutput.json* che organizza i risultati nel seguente modo:

Ogni strofa avrà un oggetto composto da synset, id e testo.

### 1.5 - SPARQL QUERY

Il passo successivo è quello di utilizzare i synset prima filtrati come input per interrogare un database semantico *framester*, in particolare con endpoint "http://etna.istc.cnr.it/framester2/sparql", al fine di ricavare informazioni riguardo alle emozioni percepite da ognuno di essi. Più nel dettaglio viene preso come parametro della funzione il *synScraperOutput.json* prima definito e per ogni verso contenuto in esso rimuoviamo la stringa "wn30" dal *sysnset* procedendo infine ad effettuare la query. Successivamente effettuiamo un'altra scrematura nei confronti di quelle risposte che non ritornano nessun tipo di informazione a noi utile. Al termine trasformiamo i dati ricavati dalla nostra richiesta in percentuali e salviamo gli stessi all'interno di un dizionario insieme al titolo, autore e divisi per strofe.

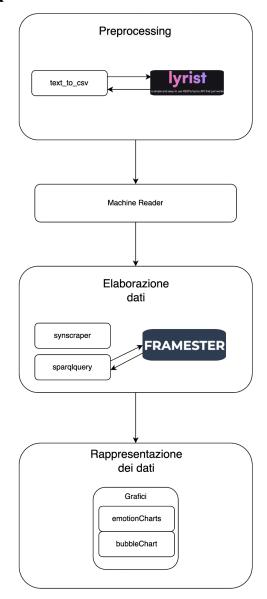
## 1.6 - Rappresentazione dei dati

Per la rappresentazione delle informazioni raccolte sono stati utilizzati grafici forniti dalla libreria per python: *matplotlib*.

In particolare vengono utilizzati:

- Un pie-chart per strofa, indicante la somma dei valori di ogni emozione della strofa.
- Una bubble-chart, con la somma complessiva di tutti i valori di ogni emozione (non build-in).
- Un line-chart, che mostra l'andamento dei valori delle emozioni nel corso della canzone.

## 1.7 - Struttura complessiva



## 2. Chat GPT

La pipeline, tramite appositi parametri, può realizzare grafici direttamente a partire da file json, in questo modo possiamo visualizzare facilmente i grafici dall'output di un qualsiasi LLM.

## **2.1 - Prompt**

Dopo varie modifiche, si è arrivati ad un prompt che potesse soddisfare i requisiti di tipi e di formattazione della pipeline e che producesse un output apparentemente sensato.

Il prompt finale usato per Chat GPT è il seguente:

#### Testo della canzone

. . .

Pretend to be an expert in emotions and return a table with the percentage of the most present emotions among anger, amusement, annoyance, indifference, happiness, inspiration, and sadness in each verse of the song above. The output should be a JSON in this format:

for each verse (number), start from zero. the value of scores must be integer, not strings

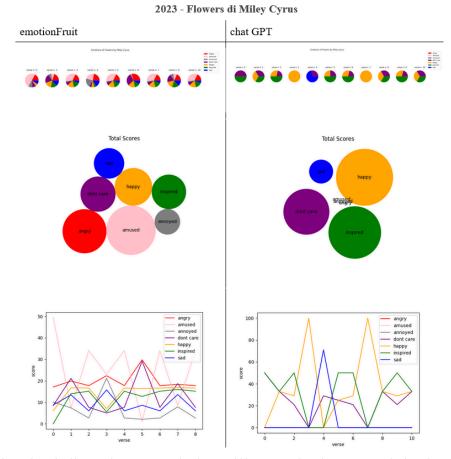
### 3. Studio del dominio

### 3.1 - Scelta del dominio

Come dominio abbiamo scelto di analizzare per ogni anno, dal 2003 al 2023, la canzone più ascoltata o popolare. Per gli anni dal 2013 al 2023 ci siamo affidati agli ascolti su Spotify, servizio streaming più utilizzato. Per gli anni dal 2003 al 2012 invece, in mancanza di Spotify, abbiamo optato per la rivista statunitense Billboard.

### 3.2 - Studio di una canzone

Riportiamo un grafico dall'appendice:



Possiamo intuire i diversi approcci che utilizzano le due metodologie.

I grafici di sinistra (generati dalla pipeline) raccolgono le parole senza tenere conto del contesto, fornendo una visione più frammentata ma allo stesso tempo, che tenga conto di tutto lo spettro di emozioni messo a disposizione.

Per i grafici di destra (generati dalla valutazione di Chat GPT) non ci è dato sapere a pieno il perchè di questa risposta. Possiamo immaginare che sarebbero le valutazioni che darebbe un essere umano anche in base ad altri "meta" elementi come: alcune informazioni sull'artista, il processo di creazione della canzone, ecc.

In questo caso notiamo che emozioni "positive" come *amused*, *happy* e *inspired* sono largamente presenti in entrambi i bubble chart. Gli andamenti rispetto alle strofe appaiono invece molto scollegati, questo potrebbe essere derivato dal fatto che gli LLM tendono a valutare solo su alcune emozioni (massimo 3 o 4) per strofa.

## 4. Github

Link Github: <a href="https://github.com/Tzumaki/emotionFruit">https://github.com/Tzumaki/emotionFruit</a>
Comandi e funzionamento sono descritti nel README.md

# 5. Appendice

# 5.1 - Pipeline vs ChatGPT

Nel file "Appendice.pdf" è possibile trovare tutti i grafici prodotti durante il progetto, sia a partire dalla pipeline che da ChatGPT, messi a confronto.